

Informe final: Predicción pre-venta de precios de viviendas

Curso: Machine Learning & Deep Learning

Proyecto: House Pricing

Tipo de solución: Regresión supervisada tabular

Unidad de análisis: Una vivienda vendida

Modelo final recomendado: XGBoost ajustado

1. Contexto del negocio y definición del problema

Contexto

Una inmobiliaria necesita recomendar un precio inicial de publicación para cada vivienda. Un precio elevado puede prolongar el tiempo de venta y disminuir la probabilidad de cierre; uno demasiado bajo puede reducir el ingreso del propietario y la comisión de la empresa. El proceso tradicional depende de comparables manuales y del criterio individual de cada analista, por lo que puede ser lento e inconsistente.

El proyecto desarrolla un sistema de apoyo que estima el precio de mercado de una vivienda **antes de que se concrete la venta**. La salida no reemplaza una tasación profesional ni garantiza el precio de cierre; proporciona una referencia cuantitativa, reproducible y explicable para apoyar la decisión del analista.

Problema de decisión

La decisión a mejorar es el precio inicial de publicación y la priorización de inmuebles que requieren revisión manual. Los usuarios son analistas de tasación, gerentes comerciales y agentes inmobiliarios.

Problema analítico

Se formuló un problema de regresión supervisada:

$$\text{SalePrice} = f(X)$$

Donde X contiene atributos físicos, de calidad, construcción, equipamiento, zona y tipología de la vivienda disponibles antes de vender. Para evitar fuga de información se excluyeron `MoSold`, `YrSold`, `SaleType` y `SaleCondition`, pues describen el cierre o la transacción ya ocurrida.

Valor esperado

- Estandarizar el proceso de valoración inicial.
- Reducir el tiempo de elaboración de una tasación preliminar.
- Priorizar inspección humana en inmuebles atípicos, de alto valor o con datos incompletos.
- Documentar recomendaciones mediante variables relevantes y métricas verificables.

2. Objetivos, alcance y criterios de éxito

Objetivo general

Construir un modelo de Machine Learning que estime el precio de una vivienda usando exclusivamente información disponible antes de la venta.

Objetivos específicos

1. Analizar calidad, estructura y faltantes de los datos.
2. Preparar variables numéricas y categóricas sin fuga de información.
3. Comparar modelos lineales y no lineales.
4. Seleccionar el modelo mediante validación y evaluarlo una sola vez en test.
5. Convertir resultados técnicos en recomendaciones operativas responsables.

Alcance

La solución estima `SalePrice` para viviendas representadas por el dataset proporcionado. Es aplicable como apoyo de precio inicial, no como tasación legal, decisión crediticia ni garantía de venta. La generalización a otra ciudad, periodo o mercado exige validación y recalibración previas.

Criterios de éxito

Criterio	Evidencia
----------	-----------

Validez del caso pre-venta	Exclusión de variables post-venta
Generalización	Métricas reportadas en test no utilizado en selección
Mejor alternativa	Comparación de Ridge, Extra Trees, XGBoost y ensemble
Interpretabilidad	Ranking de variables relevantes
Utilidad operativa	Precio sugerido, revisión humana y monitoreo
Reproducibilidad	Semilla fija, código, particiones y pipeline documentados

3. Descripción, calidad y preparación de los datos

Estructura y fuente

El archivo del dataset procede de Kaggle.com y contiene datos de 1,460 viviendas y 81 columnas, incluida la variable objetivo SalePrice. correspondientes a ventas individuales de viviendas en Ames, Iowa, desde 2006 hasta 2010. Tras excluir Id, la variable objetivo y los cuatro campos post-venta, se utilizaron 75 predictores pre-venta: 34 numéricos y 41 categóricos.

Calidad de datos

Se validaron identificadores únicos, precios positivos, duplicados y faltantes. Los faltantes no se eliminaron automáticamente: en columnas como piscina, chimenea, cerco, garaje o callejón, la ausencia puede ser información real sobre el inmueble.

Las mayores tasas de faltantes fueron: PoolQC (99.52%), MiscFeature (96.30%), Alley (93.77%), Fence (80.75%), MasVnrType (59.73%), FireplaceQu (47.26%) y LotFrontage (17.74%).

Preparación y justificación

Tipo	Tratamiento	Justificación
Numéricas faltantes	Mediana de train + indicador de ausencia	Robusto a extremos y conserva señal de faltante
Categóricas faltantes	Categoría Sin_dato	Preserva ausencia estructural
Categóricas	One-Hot Encoding y manejo de categorías infrecuentes	Evita orden artificial y reduce inestabilidad

Numéricas	RobustScaler	Reduce sensibilidad a atípicos en modelos lineales
Constantes	VarianceThreshold	Elimina columnas sin señal
Objetivo	$\log_{1p}(\text{SalePrice})$	Reduce asimetría y favorece error relativo

Ingeniería de variables

Se crearon variables disponibles antes de vender: `IsRemodeled`, `TotalSF`, `TotalBath`, `TotalPorchSF`, `HasBasement`, `HasGarage`, `HasFireplace` y `HasPool`. `MSSubClass` se trató como variable categórica porque es un código de tipología y no una escala numérica continua.

Partición y prevención de fuga

Partición	Observaciones	Proporción	Uso
Train	1,022	70%	Entrenamiento
Validación	219	15%	Selección de modelo e hiperparámetros
Test	219	15%	Evaluación final única

La partición se estratificó por deciles de precio. Imputación, escalamiento y codificación se ajustaron con train y se aplicaron a validación/test, evitando que datos futuros influyan en el aprendizaje.

4. Metodología y experimentos de modelamiento

Elección de enfoque

Se eligió Machine Learning para datos tabulares. Deep Learning no se justificó: la muestra es moderada, los predictores son estructurados y los modelos de árboles ofrecen mejor relación entre desempeño, complejidad e interpretabilidad.

Métricas

- **RMSLE:** métrica primaria; evalúa error proporcional y es coherente con $\log_{1p}(\text{SalePrice})$.
- **MAE:** error promedio en dólares, directamente interpretable por negocio.
- **RMSE:** da mayor peso a errores grandes, relevantes en inmuebles de alto valor.

- **Sesgo:** identifica sobreestimación o subestimación media.

Alternativas evaluadas

Modelo	Función en el experimento
Ridge	Referencia lineal regularizada para variables One-Hot
Extra Trees	Modelo no lineal que captura interacciones
XGBoost	Modelo principal de gradient boosting para datos tabulares
Ensemble ponderado	Combinación de XGBoost, Extra Trees y Ridge

XGBoost evaluó 24 configuraciones de `learning_rate`, `max_depth`, `min_child_weight`, `subsample`, `colsample_bytree`, `reg_lambda` y `reg_alpha`. Se aplicó early stopping para detener el aprendizaje cuando validación dejara de mejorar, reduciendo sobreajuste.

La mejor configuración observada fue: `learning_rate=0.05`, `max_depth=3`, `min_child_weight=3`, `subsample=0.75`, `colsample_bytree=0.70`, `reg_lambda=1.0` y `reg_alpha=0.05`.

5. Resultados y evaluación del modelo

Desempeño en validación

Modelo	MAE	RMSE	RMSLE	Sesgo
XGBoost ajustado	USD 13,397.727633	USD 19,731.155506	0.118945	USD 205.286137
Ensemble ponderado	USD 13,397.727705	USD 19,731.155745	0.118945	USD 205.285794
Ridge	USD 17,031.366058	USD 24,542.082727	0.141970	-USD 1,152.264177
Extra Trees	USD 17,115.149944	USD 25,140.858054	0.150754	-USD 1,800.153784

XGBoost y el ensemble empataron en RMSLE al nivel de precisión reportado. Se seleccionó **XGBoost ajustado** como modelo final porque presentó MAE y RMSE marginalmente menores, y porque el ensemble no demostró una mejora material que justificara mayor complejidad operativa.

Evaluación final en test

Métrica	Resultado
MAE	USD 16,205.48
RMSE	USD 28,249.16
RMSLE	0.143691
Sesgo	-USD 869.15

El modelo generaliza con error relativo moderado sobre viviendas no vistas. El RMSE superior al MAE indica que existen algunos errores grandes; por ello se requieren controles para inmuebles de alto valor o atributos poco frecuentes. El sesgo negativo es leve frente al MAE, pero debe monitorearse para evitar subvaloración sistemática.

6. Interpretación, impacto y recomendaciones de negocio

Variables relevantes

Ranking	Variable	Importancia	Interpretación
1	OverallQual	0.124934	La calidad global es la señal más importante de precio
2	TotalSF	0.101582	Mayor superficie total se asocia con mayor valor
3	HasFireplace	0.066850	Equipamiento y segmento de calidad
4	ExterQual_TA	0.057161	Calidad exterior diferencia segmentos
5	KitchenQual_TA	0.036940	Cocina resume calidad de terminaciones
6	GarageCars	0.034365	Capacidad de garaje agrega utilidad
7	TotalBath	0.031028	Funcionalidad y tamaño del inmueble

Estas importancias son predictivas, no causales. No deben usarse para afirmar que modificar un atributo genera necesariamente el mismo cambio de precio.

Recomendaciones accionables

1. Usar XGBoost como asistente de tasación y no como precio automático definitivo.

2. Presentar predicción central y un rango operativo inicial de predicción $\pm$ MAE de test, aproximadamente USD 16,205.
3. Exigir revisión humana para inmuebles de alto valor, categorías raras, faltantes críticos o valores fuera del rango histórico.
4. Revisar cuidadosamente calidad global, superficie, cocina, calidad exterior, baños, garaje y sótano durante la tasación.
5. Monitorear mensualmente MAE, RMSE, RMSLE y sesgo por zona y cuartil de precio.

Medición de impacto

Indicador	Medición	Criterio de éxito
Precisión	MAE y RMSLE contra precios observados	Mejorar frente al proceso manual histórico
Productividad	Minutos por tasación	Reducir tiempo sin empeorar precisión
Revisión humana	Casos remitidos a analista	Concentrar revisión en casos de riesgo
Equidad de desempeño	Error por zona y precio	No degradar sistemáticamente un segmento

7. Limitaciones y riesgos

Limitaciones

- Los datos representan un mercado, periodo y definición de variables específicos; requieren recalibración para otros contextos.
- La muestra de 1,460 observaciones puede subrepresentar inmuebles excepcionales y categorías raras.
- No se observan todas las variables que afectan precio: urgencia, negociación, fotos, estado real, competencia, tasas y condiciones financieras.
- El rango basado en MAE es una guía operativa, no un intervalo estadístico formal.
- La importancia de variables no implica causalidad.

Riesgos y mitigaciones

Riesgo	Consecuencia	Mitigación
Sobreajuste	Menor desempeño en nuevos casos	Validación/test aislados y monitoreo de brechas
Deriva de mercado	Predicciones desactualizadas	Seguimiento mensual y reentrenamiento validado
Datos deficientes	Predicción inestable	Reglas de calidad y campos obligatorios
Casos extremos	Error monetario alto	Escalamiento obligatorio a experto
Categorías nuevas	Menor confiabilidad	Manejo de desconocidos y actualización de modelo
Fuga de información	Métricas irreales	Mantener exclusión de variables post-venta
Dependencia excesiva	Decisiones incorrectas	Human-in-the-loop y trazabilidad

Ética y despliegue responsable

La zonificación puede actuar como proxy de condiciones socioeconómicas. Se debe monitorear error y sesgo por zona, tipología y rango de precio. El modelo no debe utilizarse para decisiones crediticias, discriminación o exclusión; su uso se limita a recomendación de precio y priorización de revisión.

La implementación responsable exige versionar datos y modelo, registrar cada predicción y ajuste humano, establecer umbrales de revisión obligatoria y comunicar que la salida es una estimación, no una garantía de venta.

8. Conclusiones

1. Se desarrolló un sistema de valoración pre-venta que evita fuga de información y utiliza atributos disponibles antes de la transacción.
2. La preparación de 75 predictores pre-venta fue reproducible y preservó el aislamiento de train, validación y test.
3. XGBoost ajustado fue seleccionado por desempeño competitivo y simplicidad. Empató con el ensemble en RMSLE y obtuvo MAE/RMSE marginalmente menores en validación.
4. En test, el modelo logró MAE de USD 16,205.48, RMSE de USD 28,249.16, RMSLE de 0.143691 y sesgo de -USD 869.15.
5. El modelo es útil para apoyar tasaciones iniciales y priorizar revisiones, no para sustituir el juicio profesional.

6. El siguiente paso recomendado es un piloto controlado, seguido de monitoreo por segmentos y actualización periódica del modelo.

El proyecto demuestra que es posible estimar de forma reproducible el precio de una vivienda antes de venderla. La solución mejora el proceso al aportar una recomendación cuantitativa, explicable y auditable, mientras conserva la revisión humana para los casos de mayor riesgo o incertidumbre.

9. Referencias

1. De Cock, D. (2011). *Ames, Iowa: Alternative to the Boston Housing Data as an End of Semester Regression Project*. Journal of Statistics Education, 19(3).
2. Dataset y diccionario de datos proporcionados por Kaggle.com: `train.csv` y `data_description.txt`. Nota: Si bien Kaggle.com usa el nombre `train.csv`, dicho archivo contiene el dataset completo de datos observados.
3. Zárate, J. (2026). *Rúbrica del trabajo final: Machine Learning & Deep Learning*. ESAN Graduate School of Business.
4. Documentación de Scikit-learn: Ridge, Extra Trees, imputación, RobustScaler y One-Hot Encoding.
5. Documentación de XGBoost: XGBRegressor, regularización y early stopping.
6. Perplexity AI. Apoyo de redacción y revisión técnica. El equipo ejecutó, verificó y sustentó las decisiones y resultados.