

# Informe final: Predicción pre-venta de precios de viviendas

Curso: Machine Learning & Deep Learning

Proyecto: House Pricing

Tipo de solución: Regresión supervisada tabular

Unidad de análisis: Una vivienda vendida

Modelo final recomendado: XGBoost ajustado

## 1. Contexto del negocio y definición del problema

### Contexto

Una inmobiliaria necesita recomendar un precio inicial de publicación para cada vivienda. Un precio elevado puede prolongar el tiempo de venta y disminuir la probabilidad de cierre; uno demasiado bajo puede reducir el ingreso del propietario y la comisión de la empresa. El proceso tradicional depende de comparables manuales y del criterio individual de cada analista, por lo que puede ser lento e inconsistente.

El proyecto desarrolla un sistema de apoyo que estima el precio de mercado de una vivienda **antes de que se concrete la venta**. La salida no reemplaza una tasación profesional ni garantiza el precio de cierre: proporciona una referencia cuantitativa, reproducible y explicable para apoyar la decisión del analista.

### Problema de decisión

La decisión a mejorar es el precio inicial de publicación y la priorización de inmuebles que requieren revisión manual. Los usuarios son analistas de tasación, gerentes comerciales y agentes inmobiliarios.

### Problema analítico

Se formuló un problema de regresión supervisada:

$$\text{SalePrice} = f(X)$$

Donde  $X$  contiene atributos físicos, de calidad, construcción, equipamiento, zona y tipología de la vivienda disponibles antes de vender. Para evitar fuga de información se excluyeron `MoSold`, `YrSold`, `SaleType` y `SaleCondition`, pues describen el cierre o la transacción ya ocurrida.

### Valor esperado

- Estandarizar el proceso de valoración inicial.
- Reducir el tiempo de elaboración de una tasación preliminar.
- Priorizar inspección humana en inmuebles atípicos, de alto valor o con datos incompletos.
- Documentar recomendaciones mediante variables relevantes y métricas verificables.

## 2. Objetivos, alcance y criterios de éxito

### Objetivo general

Construir un modelo de Machine Learning que estime el precio de una vivienda usando exclusivamente información disponible antes de la venta.

### Objetivos específicos

1. Analizar calidad, estructura y faltantes de los datos.
2. Preparar variables numéricas y categóricas sin fuga de información.
3. Comparar modelos lineales y no lineales.
4. Seleccionar el modelo mediante validación y evaluarlo una sola vez en test.
5. Convertir resultados técnicos en recomendaciones operativas responsables.

### Alcance

La solución estima SalePrice para viviendas representadas por el dataset proporcionado. Es aplicable como apoyo de precio inicial, no como tasación legal, decisión crediticia ni garantía de venta. La generalización a otra ciudad, periodo o mercado exige validación y recalibración previas.

### Criterios de éxito

| Criterio                   | Evidencia                                                 |
|----------------------------|-----------------------------------------------------------|
| Validez del caso pre-venta | Exclusión de variables post-venta                         |
| Generalización             | Métricas reportadas en test no utilizado en selección     |
| Mejor alternativa          | Comparación de Ridge, Extra Trees, XGBoost y ensemble     |
| Interpretabilidad          | Ranking de variables relevantes                           |
| Utilidad operativa         | Precio sugerido, revisión humana y monitoreo              |
| Reproducibilidad           | Semilla fija, código, particiones y pipeline documentados |

### 3. Descripción, calidad y preparación de los datos

#### Estructura y fuente

El archivo de entrenamiento contiene 1,460 viviendas y 81 columnas, incluida la variable objetivo SalePrice. Tras excluir Id, la variable objetivo y los cuatro campos post-venta, se utilizaron 75 predictores pre-venta: 34 numéricos y 41 categóricos.

#### Calidad de datos

Se validaron identificadores únicos, precios positivos, duplicados y faltantes. Los faltantes no se eliminaron automáticamente: en columnas como piscina, chimenea, cerco, garaje o callejón, la ausencia puede ser información real sobre el inmueble.

Las mayores tasas de faltantes fueron: PoolQC (99.52%), MiscFeature (96.30%), Alley (93.77%), Fence (80.75%), MasVnrType (59.73%), FireplaceQu (47.26%) y LotFrontage (17.74%).

#### Preparación y justificación

| Tipo                  | Tratamiento                                          | Justificación                                      |
|-----------------------|------------------------------------------------------|----------------------------------------------------|
| Numéricas faltantes   | Mediana de train + indicador de ausencia             | Robusto a extremos y conserva señal de faltante    |
| Categóricas faltantes | Categoría Sin_dato                                   | Preserva ausencia estructural                      |
| Categóricas           | One-Hot Encoding y manejo de categorías infrecuentes | Evita orden artificial y reduce inestabilidad      |
| Numéricas             | RobustScaler                                         | Reduce sensibilidad a atípicos en modelos lineales |
| Constantes            | VarianceThreshold                                    | Elimina columnas sin señal                         |
| Objetivo              | log1p(SalePrice)                                     | Reduce asimetría y favorece error relativo         |

#### Ingeniería de variables

Se crearon variables disponibles antes de vender: IsRemodeled, TotalSF, TotalBath, TotalPorchSF, HasBasement, HasGarage, HasFireplace y HasPool. MSSubClass se trató como variable categórica porque es un código de tipología y no una escala numérica continua.

#### Partición y prevención de fuga

| Partición  | Observaciones | Proporción | Uso                                   |
|------------|---------------|------------|---------------------------------------|
| Train      | 1,022         | 70%        | Entrenamiento                         |
| Validación | 219           | 15%        | Selección de modelo e hiperparámetros |
| Test       | 219           | 15%        | Evaluación final única                |

La partición se estratificó por deciles de precio. Imputación, escalamiento y codificación se ajustaron con train y se aplicaron a validación/test, evitando que datos futuros influyan en el aprendizaje.

## 4. Metodología y experimentos de modelamiento

### Elección de enfoque

Se eligió Machine Learning para datos tabulares. Deep Learning no se justificó: la muestra es moderada, los predictores son estructurados y los modelos de árboles ofrecen mejor relación entre desempeño, complejidad e interpretabilidad.

### Métricas

- **RMSLE**: métrica primaria; evalúa error proporcional y es coherente con  $\log_{1p}(\text{SalePrice})$ .
- **MAE**: error promedio en dólares, directamente interpretable por negocio.
- **RMSE**: da mayor peso a errores grandes, relevantes en inmuebles de alto valor.
- **Sesgo**: identifica sobreestimación o subestimación media.

### Alternativas evaluadas

| Modelo             | Función en el experimento                                  |
|--------------------|------------------------------------------------------------|
| Ridge              | Referencia lineal regularizada para variables One-Hot      |
| Extra Trees        | Modelo no lineal que captura interacciones                 |
| XGBoost            | Modelo principal de gradient boosting para datos tabulares |
| Ensemble ponderado | Combinación de XGBoost, Extra Trees y Ridge                |

XGBoost evaluó 24 configuraciones de `learning_rate`, `max_depth`, `min_child_weight`, `subsample`, `colsample_bytree`, `reg_lambda` y `reg_alpha`. Se aplicó early stopping para detener el aprendizaje cuando validación dejara de mejorar, reduciendo sobreajuste.

La mejor configuración observada fue: `learning_rate=0.05`, `max_depth=3`, `min_child_weight=3`, `subsample=0.75`, `colsample_bytree=0.70`, `reg_lambda=1.0` y `reg_alpha=0.05`.

## 5. Resultados y evaluación del modelo

### Desempeño en validación

| Modelo             | MAE               | RMSE              | RMSLE           | Sesgo             |
|--------------------|-------------------|-------------------|-----------------|-------------------|
| XGBoost ajustado   | USD 13,397.727633 | USD 19,731.155506 | <b>0.118945</b> | USD 205.286137    |
| Ensemble ponderado | USD 13,397.727705 | USD 19,731.155745 | <b>0.118945</b> | USD 205.285794    |
| Ridge              | USD 17,031.366058 | USD 24,542.082727 | 0.141970        | -USD 1,152.264177 |

| Modelo      | MAE               | RMSE              | RMSLE    | Sesgo             |
|-------------|-------------------|-------------------|----------|-------------------|
| Extra Trees | USD 17,115.149944 | USD 25,140.858054 | 0.150754 | -USD 1,800.153784 |

XGBoost y el ensemble empataron en RMSLE al nivel de precisión reportado. Se seleccionó **XGBoost ajustado** como modelo final porque presentó MAE y RMSE marginalmente menores, y porque el ensemble no demostró una mejora material que justificara mayor complejidad operativa.

### Evaluación final en test

| Métrica | Resultado     |
|---------|---------------|
| MAE     | USD 16,205.48 |
| RMSE    | USD 28,249.16 |
| RMSLE   | 0.143691      |
| Sesgo   | -USD 869.15   |

El modelo generaliza con error relativo moderado sobre viviendas no vistas. El RMSE superior al MAE indica que existen algunos errores grandes; por ello se requieren controles para inmuebles de alto valor o atributos poco frecuentes. El sesgo negativo es leve frente al MAE, pero debe monitorearse para evitar subvaloración sistemática.

## 6. Interpretación, impacto y recomendaciones de negocio

### Variables relevantes

| Ranking | Variable       | Importancia | Interpretación                                         |
|---------|----------------|-------------|--------------------------------------------------------|
| 1       | OverallQual    | 0.124934    | La calidad global es la señal más importante de precio |
| 2       | TotalSF        | 0.101582    | Mayor superficie total se asocia con mayor valor       |
| 3       | HasFireplace   | 0.066850    | Equipamiento y segmento de calidad                     |
| 4       | ExterQual_TA   | 0.057161    | Calidad exterior diferencia segmentos                  |
| 5       | KitchenQual_TA | 0.036940    | Cocina resume calidad de terminaciones                 |
| 6       | GarageCars     | 0.034365    | Capacidad de garaje agrega utilidad                    |
| 7       | TotalBath      | 0.031028    | Funcionalidad y tamaño del inmueble                    |

Estas importancias son predictivas, no causales. No deben usarse para afirmar que modificar un atributo genera necesariamente el mismo cambio de precio.

### Recomendaciones accionables

1. Usar XGBoost como asistente de tasación y no como precio automático definitivo.
2. Presentar predicción central y un rango operativo inicial de predicción  $\pm$  MAE de test, aproximadamente USD 16,205.
3. Exigir revisión humana para inmuebles de alto valor, categorías raras, faltantes críticos o valores fuera del rango histórico.
4. Revisar cuidadosamente calidad global, superficie, cocina, calidad exterior, baños, garaje y sótano durante la tasación.
5. Monitorear mensualmente MAE, RMSE, RMSLE y sesgo por zona y cuartil de precio.

### Medición de impacto

| Indicador            | Medición                              | Criterio de éxito                          |
|----------------------|---------------------------------------|--------------------------------------------|
| Precisión            | MAE y RMSLE contra precios observados | Mejorar frente al proceso manual histórico |
| Productividad        | Minutos por tasación                  | Reducir tiempo sin empeorar precisión      |
| Revisión humana      | Casos remitidos a analista            | Concentrar revisión en casos de riesgo     |
| Equidad de desempeño | Error por zona y precio               | No degradar sistemáticamente un segmento   |

## 7. Limitaciones y riesgos

### Limitaciones

- Los datos representan un mercado, periodo y definición de variables específicos; requieren recalibración para otros contextos.
- La muestra de 1,460 observaciones puede subrepresentar inmuebles excepcionales y categorías raras.
- No se observan todas las variables que afectan precio: urgencia, negociación, fotos, estado real, competencia, tasas y condiciones financieras.
- El rango basado en MAE es una guía operativa, no un intervalo estadístico formal.
- La importancia de variables no implica causalidad.

### Riesgos y mitigaciones

| Riesgo            | Consecuencia                    | Mitigación                                       |
|-------------------|---------------------------------|--------------------------------------------------|
| Sobreajuste       | Menor desempeño en nuevos casos | Validación/test aislados y monitoreo de brechas  |
| Deriva de mercado | Predicciones desactualizadas    | Seguimiento mensual y reentrenamiento validado   |
| Datos deficientes | Predicción inestable            | Reglas de calidad y campos obligatorios          |
| Casos extremos    | Error monetario alto            | Escalamiento obligatorio a experto               |
| Categorías nuevas | Menor confiabilidad             | Manejo de desconocidos y actualización de modelo |

| Riesgo               | Consecuencia           | Mitigación                                 |
|----------------------|------------------------|--------------------------------------------|
| Fuga de información  | Métricas irreales      | Mantener exclusión de variables post-venta |
| Dependencia excesiva | Decisiones incorrectas | Human-in-the-loop y trazabilidad           |

## Ética y despliegue responsable

La zonificación puede actuar como proxy de condiciones socioeconómicas. Se debe monitorear error y sesgo por zona, tipología y rango de precio. El modelo no debe utilizarse para decisiones crediticias, discriminación o exclusión; su uso se limita a recomendación de precio y priorización de revisión.

La implementación responsable exige versionar datos y modelo, registrar cada predicción y ajuste humano, establecer umbrales de revisión obligatoria y comunicar que la salida es una estimación, no una garantía de venta.

## 8. Conclusiones

1. Se desarrolló un sistema de valoración pre-venta que evita fuga de información y utiliza atributos disponibles antes de la transacción.
2. La preparación de 75 predictores pre-venta fue reproducible y preservó el aislamiento de train, validación y test.
3. XGBoost ajustado fue seleccionado por desempeño competitivo y simplicidad. Empató con el ensemble en RMSLE y obtuvo MAE/RMSE marginalmente menores en validación.
4. En test, el modelo logró MAE de USD 16,205.48, RMSE de USD 28,249.16, RMSLE de 0.143691 y sesgo de -USD 869.15.
5. El modelo es útil para apoyar tasaciones iniciales y priorizar revisiones, no para sustituir el juicio profesional.
6. El siguiente paso recomendado es un piloto controlado, seguido de monitoreo por segmentos y actualización periódica del modelo.

El proyecto demuestra que es posible estimar de forma reproducible el precio de una vivienda antes de venderla. La solución mejora el proceso al aportar una recomendación cuantitativa, explicable y auditable, mientras conserva la revisión humana para los casos de mayor riesgo o incertidumbre.

## 9. Referencias y anexos

### Referencias

1. De Cock, D. (2011). *Ames, Iowa: Alternative to the Boston Housing Data as an End of Semester Regression Project*. Journal of Statistics Education, 19(3).
2. Dataset y diccionario de datos proporcionados: `train.csv` y `data_description.txt`.

3. Zárate, J. (2026). *Rúbrica del trabajo final: Machine Learning & Deep Learning*. ESAN Graduate School of Business.
4. Documentación de Scikit-learn: Ridge, Extra Trees, imputación, RobustScaler y One-Hot Encoding.
5. Documentación de XGBoost: `XGBRegressor`, regularización y early stopping.
6. Perplexity AI. Apoyo de redacción y revisión técnica. El equipo ejecutó, verificó y sustentó las decisiones y resultados.

## Anexos sugeridos

- Notebook ejecutado `House_Pricing.ipynb`.
- Tablas de las 24 configuraciones evaluadas de XGBoost.
- Comparación de modelos en validación.
- Tabla final de métricas en test.
- Gráfico de precio real versus predicho.
- Gráfico de residuos.
- Gráfico de importancia de variables.
- Diccionario de datos.
- Semilla utilizada: `RANDOM_STATE = 42`.